

# Chapter 6: Mining Frequent Patterns, Association and Correlations: Basic Concepts and Methods

---


☐ Basic Concepts



☐ Efficient Pattern Mining Methods

☐ Pattern Evaluation

☐ Summary



Mining frequent patterns  
from patterns ที่ซ่อนอยู่ใน Data

# What Is Pattern Discovery?

## What are patterns?

ข้อมูลหลายๆ อย่างที่มักเจอร่วมกัน (patterns การซื้อของคน), set of items มักจะเกิดขึ้นซ้ำๆ

**Patterns:** A set of items, subsequences, or substructures that occur frequently together (or strongly correlated) in a data set

Patterns represent **intrinsic** and **important properties** of datasets

## Pattern discovery: Uncovering patterns from massive data sets

## Motivation examples:

What products were often purchased together? สินค้าอะไรที่คนจะซื้อพร้อมกันเสมอ

What are the subsequent purchases after buying an iPad? แล้วจากที่ซื้อสิ่งหนึ่งไปแล้ว ครั้งหน้าจะซื้ออะไร

What code segments likely contain copy-and-paste bugs? มี code ของคนที่ทำก่อนหน้ามา

What word sequences likely form phrases in this corpus? ใช้กันบ่อยมาก แต่จะมี bug หรือ "ดูตัวแปรด้วย"



# Basic Concepts: k-Itemsets and Their Supports

"อันไหนที่บ่อย"

- ☐ **Itemset**: A set of one or more items  
*ไอเทมเซตคือกลุ่มของไอเทมที่ซื้อร่วมกัน*
- ☐ **k-itemset**:  $X = \{x_1, \dots, x_k\}$   
*ไอเทมเซตที่มีสมาชิก k ตัว*
- ☐ Ex. {Beer, Nuts, Diaper} is a 3-itemset  
*(เบียร์, ถั่ว, ผ้าอ้อม) 3 ไอเทม*
- ☐ **(absolute) support (count)** of X,  $\text{sup}\{X\}$ :  
Frequency or the number of occurrences of an itemset X  
*จำนวนของ transaction ที่ support ไอเทมเซตนั้น*
- ☐ Ex.  $\text{sup}\{\text{Beer}\} = 3$   
*จำนวน transaction ที่มีเบียร์*
- ☐ Ex.  $\text{sup}\{\text{Diaper}\} = 4$   
*จำนวน transaction ที่มีผ้าอ้อม*
- ☐ Ex.  $\text{sup}\{\text{Beer, Diaper}\} = 3$   
*จำนวน transaction ที่มีทั้งเบียร์และผ้าอ้อม*
- ☐ Ex.  $\text{sup}\{\text{Beer, Eggs}\} = 1$

Tid	Items bought
10	Beer, Nuts, Diaper <i>transaction ID คือ 10 มี 1 ในประวัติ</i>
20	Beer, Coffee, Diaper
30	Beer, Diaper, Eggs
40	Nuts, Eggs, Milk
50	Nuts, Coffee, Diaper, Eggs, Milk

- ☐ **(relative) support**,  $s\{X\}$ : The fraction of transactions that contains X (i.e., the **probability** that a transaction contains X)  
*สัดส่วนของ transaction ที่ support ไอเทมเซตนั้น*
- ☐ Ex.  $s\{\text{Beer}\} = \frac{3}{5} = 60\%$   
*จากทั้งหมดคือ 3 ใน 5 (จำนวน transaction ทั้งหมด)*
- ☐ Ex.  $s\{\text{Diaper}\} = \frac{4}{5} = 80\%$
- ☐ Ex.  $s\{\text{Beer, Eggs}\} = \frac{1}{5} = 20\%$

# Basic Concepts: Frequent Itemsets (Patterns)

- An itemset (or a pattern)  $X$  is *frequent* if the support of  $X$  is no less than a *minsup* threshold  $\sigma$

กฎการนับ  
ขั้นต่ำ 50%

- Let  $\sigma = 50\%$  ( $\sigma$ : *minsup* threshold)

For the given 5-transaction dataset

- All the frequent 1-itemsets:

Beer มี 3 transaction คือ 60%.

- Beer: 3/5 (60%); Nuts: 3/5 (60%)

- Diaper: 4/5 (80%); Eggs: 3/5 (60%)

- All the frequent 2-itemsets:

มี beer กับ Diaper คู่กันอยู่ 3 transaction = 60%.

- {Beer, Diaper}: 3/5 (60%)

- All the frequent 3-itemsets?

- None

- coffee : 2/5 (40%)  $\Rightarrow$  ไม่ผ่านเกณฑ์

Tid	Items bought
10	Beer, Nuts, Diaper
20	Beer, Coffee, Diaper
30	Beer, Diaper, Eggs
40	Nuts, Eggs, Milk
50	Nuts, Coffee, Diaper, Eggs, Milk

- Why do these itemsets (shown on the left) form the complete set of frequent  $k$ -itemsets (patterns) for any  $k$ ?
- **Observation:** We may need an efficient method to mine a complete set of frequent patterns



# From Frequent Itemsets to Association Rules

- Comparing with itemsets, rules can be more telling

Ex.  $Diaper \rightarrow Beer$  คนซื้อ Diaper เข้าไปซื้อ Beer

*Buying diapers may likely lead to buying beers*

- How strong is this rule? (support, confidence) ยิ่ง support ยิ่งน้อย แต่ support มากๆ ไม่ผิดอะไรในแง่ของสถิติ

Measuring association rules:  $X \rightarrow Y (s, c)$

Both X and Y are itemsets

**Support**, s: The probability that a transaction contains  $X \cup Y$

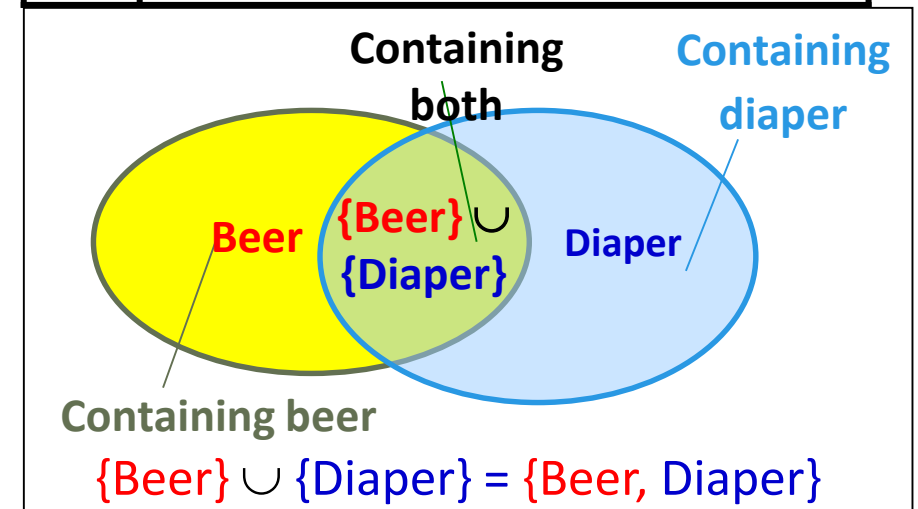
Ex.  $s\{Diaper, Beer\} = 3/5 = 0.6$  (i.e., 60%) sup 1 ต่อ 0.6

**Confidence**, c: The *conditional probability* that a transaction containing X also contains Y

Calculation:  $c = \frac{\text{sup}(X \cup Y)}{\text{sup}(X)}$  sup ของ 2 อย่างรวมกัน / sup อย่างนั้น

Ex.  $c = \frac{\text{sup}\{Diaper, Beer\}}{\text{sup}\{Diaper\}} = \frac{3}{4} = 0.75$  Diaper/Beer 3/4

Tid	Items bought
10	Beer, Nuts, Diaper
20	Beer, Coffee, Diaper
30	Beer, Diaper, Eggs
40	Nuts, Eggs, Milk
50	Nuts, Coffee, Diaper, Eggs, Milk



Note:  $X \cup Y$ : the union of two itemsets  
 ■ The set contains both X and Y

# Mining Frequent Itemsets and Association Rules

## Association rule mining

- Given two thresholds:  $minsup$ ,  $minconf$
- Find **all** of the rules,  $X \rightarrow Y$  (s, c)
  - such that,  $s \geq minsup$  and  $c \geq minconf$

Let  $minsup = 50\%$  → เป็นไอเทมเซตที่มีอยู่เป็นส่วนใหญ่ของทุกไอเทมเซต

- Freq. 1-itemsets: Beer: 3, Nuts: 3, Diaper: 4, Eggs: 3
- Freq. 2-itemsets: {Beer, Diaper}: 3

Let  $minconf = 50\%$  <sup>เกิดขึ้นซ้ำกันมากหรือไม่</sup>  $Sup(Beer/Diaper)/Sup(Beer)$

- $Beer \rightarrow Diaper$  (60%, 100%) <sup>ng 2 ตัว</sup>  $\rightarrow$  100 Diaper ไปจนถึง Beer
- $Diaper \rightarrow Beer$  (60%, 75%)

(Q: Are these all rules?)

Tid	Items bought
10	Beer, Nuts, Diaper
20	Beer, Coffee, Diaper
30	Beer, Diaper, Eggs
40	Nuts, Eggs, Milk
50	Nuts, Coffee, Diaper, Eggs, Milk

## Observations:

- Mining association rules and mining frequent patterns are very close problems
- Scalable methods are needed for mining large datasets



# Efficient Pattern Mining Methods

---

- ❑ The Downward Closure Property of Frequent Patterns
- ❑ The Apriori Algorithm
- ❑ Extensions or Improvements of Apriori
- ❑ Mining Frequent Patterns by Exploring Vertical Data Format
- ❑ FPGrowth: A Frequent Pattern-Growth Approach
- ❑ Mining Closed Patterns



# Apriori Pruning and Scalable Mining Methods

- Apriori pruning principle: <sup>ตัดแต่ง</sup> If there is any itemset which is <sup>: ถ้าเกิดว่าไอเทมเซตที่ต่ำกว่า ไม่ผ่าน minsup ไอเทมเซตที่สูงกว่าก็ไม่ต้องผ่าน Minusup (ไม่ต้องทำ)</sup> infrequent, its superset should not even be generated! (Agrawal & Srikant @VLDB'94, Mannila, et al. @ KDD' 94)
- Scalable mining Methods: Three major approaches
  - Level-wise, join-based approach: Apriori (Agrawal & Srikant@VLDB'94)
  - Vertical data format approach: Eclat (Zaki, Parthasarathy, Ogihara, Li @KDD'97)
  - Frequent pattern projection and growth: FPgrowth (Han, Pei, Yin @SIGMOD'00)





# Apriori: A Candidate Generation & Test Approach

การเลือกเป็นขั้นตอนนี้

□ Outline of Apriori (level-wise, candidate generation and test)

□ Initially, scan DB once to get frequent 1-itemset

สามารถเริ่มจาก 1 ไอเทมที่พบบ่อย

□ Repeat


□ Generate length-(k+1) candidate itemsets from length-k frequent itemsets

□ Test the candidates against DB to find frequent (k+1)-itemsets

□ Set  $k := k + 1$

□ Until no frequent or candidate set can be generated

□ Return all the frequent itemsets derived



# The Apriori Algorithm—An Example

Database TDB

Tid	Items
10	A, C, D
20	B, C, E
30	A, B, C, E
40	B, E

กำหนด minsup = 2  
minsup = 2

$C_1$

1<sup>st</sup> scan  
หา 1 itemset

มี 4 รายการ

ตาราง oneItemset

Itemset	sup
{A}	2
{B}	3
{C}	3
{D}	1
{E}	3

$F_1$

ได้ตารางใหม่ ลำดับที่ 1

Itemset	sup
{A}	2
{B}	3
{C}	3
{E}	3

จับคู่ Itemset

$F_2$

ตารางใหม่ ลำดับที่ 2

Itemset	sup
{A, C}	2
{B, C}	2
{B, E}	3
{C, E}	2

$C_2$

แสดงคู่ที่ตรงกับ minsup หรือไม่

Itemset	sup
<del>{A, B}</del>	<del>1</del>
{A, C}	2
<del>{A, E}</del>	<del>1</del>
{B, C}	2
{B, E}	3
{C, E}	2

2<sup>nd</sup> scan

$C_2$

ได้

Itemset
{A, B}
{A, C}
{A, E}
{B, C}
{B, E}
{C, E}

$C_3$

สร้าง tree Itemset

Itemset
{B, C, E}

3<sup>rd</sup> scan

$F_3$

ลำดับสุดท้าย

Itemset	sup
{B, C, E}	2

จับคู่ได้ 8 คู่ แต่ไม่ผ่าน minsup